

03 — Warps, SIMT e Warp Scheduling

Pré-requisito: [02 — threads, blocks e grids](#) e SIMD da Phase 1.

1. Warp: a unidade operacional

Threads consecutivas de um block são agrupadas em **warps de 32 lanes**. O modelo CUDA apresenta threads com registradores, índices e fluxo de controle próprios, mas o hardware agrupa lanes ativas de um warp para executar uma instrução comum. Isso é **SIMT — Single Instruction, Multiple Threads**.

```
warp: lane 0  lane 1  ... lane 31
      thread  thread        thread
          \      |      /
           instrução emitida
```

2. SIMD não é SIMT com outro nome

Em SIMD, uma instrução vetorial opera sobre posições de um registrador vetorial e há um fluxo de controle explícito. Em SIMT, o programador escreve threads escalares, cada uma com estado lógico próprio; o hardware as agrupa. Essa abstração permite branches por thread, mas diferenças dentro do warp criam máscaras e potencial divergência.

Desde Volta, **Independent Thread Scheduling** mantém estado por thread. Portanto, código que pressupõe sincronização implícita entre lanes é frágil; use primitivas como `__syncwarp()` quando a comunicação intra-warp exigir ordem.

3. Resident, ready, eligible, issued

- **Resident:** estado do warp está alocado no SM.
- **Ready:** dependências da próxima instrução foram satisfeitas.
- **Eligible:** ready e apto a ser escolhido pelo scheduler naquele ciclo.
- **Issued:** o scheduler efetivamente enviou a instrução a uma unidade.

Occupancy conta warps **residentes**, não garante que estejam ready/eligible. Quarenta e oito warps esperando a mesma dependência não fornecem trabalho útil ao scheduler.

4. Trocar de warp é barato

O estado dos warps residentes já está no SM, especialmente em registradores. Quando um warp espera um load, o scheduler pode emitir instrução de outro warp pronto sem troca de contexto de sistema operacional. Essa é a base de latency hiding desenvolvida no arquivo 08.

Pergunta rápida

Um SM tem 24 warps residentes, mas apenas 1 está eligible. A occupancy pode parecer razoável; o throughput de emissão precisa ser alto?

► Resposta

O que guardar

- Warp tem 32 lanes e é a unidade de emissão relevante para coalescing/divergência.
- SIMT oferece estado lógico por thread, não um vetor rígido exposto pelo programa.
- Resident não significa ready; ready não significa issued.

Conexão: para saber por que um warp deixa de ficar ready, precisamos mapear onde seus dados vivem e quanto custa alcançá-los.

Fonte primária: [CUDA Programming Guide — Programming Model](#).